

Proposal Proyek

Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Siti Aisyah Febriyanti (24031554158)
Anggota 1	Arimbi Deby Setyoningrum (24031554186)
Anggota 2	Mutiara Nur Fadhilatun Nimah (24031554116)
URL Github	https://github.com/kicaw-mania

Informasi Umum Proyek



Judul	Deteksi Dini Penyakit Daun Jagung Menggunakan Convolutional Neural Network dan Ensemble Classifier untuk Mendukung Ketahanan Pangan
Topik	Pangan
Pilihan Rumusan Masalah	1.2 Lambatnya Adopsi Teknologi dan Transformasi Digital dalam Ekosistem Pangan <i>lihat: https://risbang.kemdiktisaintek.go.id/rumusan-masalah.html</i>
Revisi?	<i>Ya / Tidak</i>

Deskripsi Rumusan masalah	Jagung merupakan salah satu komoditas pangan strategis yang berperan penting dalam mendukung ketahanan pangan nasional. Namun, produktivitas tanaman jagung masih sering menurun akibat serangan penyakit daun yang dapat menyebabkan kerusakan tanaman hingga gagal panen. Permasalahan ini menjadi penting karena deteksi penyakit secara dini diperlukan untuk mengurangi kerugian dan meningkatkan hasil produksi pertanian. Saat ini, identifikasi penyakit daun jagung masih banyak dilakukan secara manual sehingga membutuhkan waktu, bergantung pada tenaga ahli, dan rentan terhadap kesalahan identifikasi akibat kemiripan gejala antar penyakit. Selain itu, variasi kondisi citra dan pola visual daun menjadi tantangan dalam proses klasifikasi penyakit. Penelitian ini relevan dengan rumusan masalah pangan poin 1.2 yaitu “Lambatnya Adopsi Teknologi dan Transformasi Digital dalam Ekosistem Pangan”, karena penelitian memanfaatkan teknologi pembelajaran mesin sebagai bagian dari penerapan transformasi digital dan smart agriculture untuk mendukung deteksi dini penyakit tanaman dan meningkatkan produktivitas pada sektor pangan.
Tujuan penelitian (Objectives)	Adapun tujuan dari penelitian ini adalah sebagai berikut: 1. Melakukan <i>pre-processing</i> dan ekstraksi fitur citra daun jagung menggunakan <i>Convolutional Neural Network</i> (CNN) untuk memperoleh representasi fitur visual penyakit daun jagung.

	- Mengimplementasikan <i>Random Forest</i> dan <i>XGBoost</i> sebagai <i>ensemble classifier</i> untuk melakukan klasifikasi jenis penyakit daun jagung berdasarkan fitur hasil ekstraksi CNN. - Melakukan evaluasi dan analisis performa model klasifikasi menggunakan metrik <i>accuracy</i>, <i>precision</i>, <i>recall</i>, dan <i>f1-score</i> guna mendukung deteksi dini penyakit tanaman pada sektor pangan.
Referensi penelitian	Adapun referensi penelitian ini adalah sebagai berikut: https://doi.org/10.1016/j.bspc.2024.106089 http://doi.org/10.11591/jjeecs.v29.i2.pp1030-1038 https://doi.org/10.1016/j.atech.2023.100362


Informasi Detail Dataset

Sumber dataset	Dataset yang digunakan pada penelitian ini adalah dataset citra penyakit daun jagung (<u>Corn or Maize Leaf Disease Dataset</u>) yang diperoleh dari platform Kaggle. Dataset ini berisi kumpulan citra daun jagung yang terbagi ke dalam beberapa kategori penyakit, yaitu <i>Blight</i>, <i>Common Rust</i>, <i>Gray Leaf Spot</i>, serta daun sehat (<i>Healthy</i>). Dataset tersebut digunakan untuk mendukung proses klasifikasi penyakit tanaman jagung berbasis citra digital menggunakan metode <i>machine learning</i> dan <i>deep learning</i>.																					
Deskripsi awal fitur dataset	Dataset citra penyakit daun jagung ini berupa file gambar daun jagung dengan format citra berwarna (RGB <i>image</i>). Selain citra, dataset juga memiliki beberapa atribut pendukung yang menjelaskan karakteristik teknis dari masing-masing gambar, seperti ukuran resolusi, jumlah kanal warna, serta ukuran file gambar. Informasi ini penting untuk mengetahui kualitas dan keragaman data sebelum dilakukan tahap preprocessing dan pelatihan model. Tabel 1. Deskripsi Fitur Dataset <table> <tr> <th>Nama Atribut</th> <th>Deskripsi</th> <th>Tipe Data</th> </tr> <tr> <td>Filename</td> <td>Nama file citra</td> <td>Object</td> </tr> <tr> <td>Label</td> <td>Jenis penyakit daun jagung (Blight, Object Common_Rust, Gray_Leaf_Spot, Healthy)</td> <td></td> </tr> <tr> <td>Channels</td> <td>Jumlah channel warna pada citra</td> <td>int</td> </tr> <tr> <td>Width</td> <td>Lebar resolusi gambar</td> <td>int</td> </tr> <tr> <td>Height</td> <td>Tinggi resolusi gambar</td> <td>int</td> </tr> <tr> <td>File size</td> <td>Ukuran file citra gambar</td> <td>float</td> </tr> </table> Berdasarkan Tabel 1, atribut Label digunakan sebagai target klasifikasi, sedangkan atribut lainnya digunakan untuk menggambarkan karakteristik teknis dari citra yang digunakan pada penelitian. Untuk mengetahui gambaran umum data numerik, dilakukan analisis statistik deskriptif yang disajikan pada Tabel 2.	Nama Atribut	Deskripsi	Tipe Data	Filename	Nama file citra	Object	Label	Jenis penyakit daun jagung (Blight, Object Common_Rust, Gray_Leaf_Spot, Healthy)		Channels	Jumlah channel warna pada citra	int	Width	Lebar resolusi gambar	int	Height	Tinggi resolusi gambar	int	File size	Ukuran file citra gambar	float
Nama Atribut	Deskripsi	Tipe Data																				
Filename	Nama file citra	Object																				
Label	Jenis penyakit daun jagung (Blight, Object Common_Rust, Gray_Leaf_Spot, Healthy)																					
Channels	Jumlah channel warna pada citra	int																				
Width	Lebar resolusi gambar	int																				
Height	Tinggi resolusi gambar	int																				
File size	Ukuran file citra gambar	float																				

	Tabel 2. Statistik Deskriptif Dataset <table><thead><tr><th></th><th>Width</th><th>Height</th><th>Channels</th><th>File Size</th></tr></thead><tbody><tr><td>Mean</td><td>307.53</td><td>297.9</td><td>3.001</td><td>39.91</td></tr><tr><td>Std</td><td>285.71</td><td>253.13</td><td>0.034</td><td>227.46</td></tr><tr><td>min</td><td>180</td><td>116</td><td>3</td><td>3.78</td></tr><tr><td>max</td><td>5184</td><td>5184</td><td>4</td><td>6419.98</td></tr></tbody></table> Berdasarkan Tabel 2, ukuran citra pada dataset memiliki variasi yang cukup besar, baik dari segi resolusi maupun ukuran file. Selain itu, sebagian besar gambar memiliki tiga <i>channel</i> warna (RGB). Variasi tersebut menunjukkan perlunya tahap <i>preprocessing</i> seperti <i>resizing</i> dan normalisasi sebelum proses pelatihan model dilakukan. Untuk memberikan gambaran visual mengenai dataset yang digunakan, ditampilkan beberapa sampel citra daun jagung dari masing-masing kelas penyakit. Visualisasi ini bertujuan untuk menunjukkan perbedaan karakteristik visual pada setiap kategori penyakit daun jagung.     (a) (b) (c) (d) Gambar 1. Visualisasi Sampel tiap Kelas (a) Blight, (b) <i>Common Rust</i>, (c) <i>Gray Leaf Spot</i>, (d) <i>Healthy</i> Gambar 1 menunjukkan contoh citra daun jagung pada masing-masing kelas dataset, yaitu <i>Blight</i>, <i>Common Rust</i>, <i>Gray Leaf Spot</i>, dan <i>Healthy</i>. Setiap kelas memiliki karakteristik visual yang berbeda, seperti bercak, perubahan warna daun, dan pola kerusakan tertentu.		Width	Height	Channels	File Size	Mean	307.53	297.9	3.001	39.91	Std	285.71	253.13	0.034	227.46	min	180	116	3	3.78	max	5184	5184	4	6419.98
	Width	Height	Channels	File Size																						
Mean	307.53	297.9	3.001	39.91																						
Std	285.71	253.13	0.034	227.46																						
min	180	116	3	3.78																						
max	5184	5184	4	6419.98																						
Aspek khusus dari dataset	1. Berikut merupakan sebaran distribusi <i>sparsity</i>.  Gambar 2. Distribusi <i>sparsity</i> Hasil dari <i>sparsity</i> yang kami lakukan menunjukkan bahwa dataset memiliki tingkat <i>sparsity</i> sebesar 4,664%. Nilai ini menunjukkan bahwa proporsi data kosong atau area informasi yang mini dalam dataset ini																									

sangat rendah. Dengan persentase *sparsity* yang kecil, dataset dapat dikategorikan cukup padat (*dense*), sehingga informasi visual yang tersedia masih memadai untuk proses analisis maupun pelatihan model.


2. Berikut merupakan persebaran dataset berdasarkan labelnya .



Gambar 3. Distribusi Kelas

Distribusi jumlah data pada masing masing kelas berdasarkan gambar 3, menunjukkan adanya kondisi kelas tidak seimbang. Rasio distribusi kelas yang diperoleh adalah 2,00:2,28:1,00:2,02 , yang menunjukkan bahwa salah satu kelas memiliki jumlah nilai data yang lebih kecil dibandingkan kelas lain. Hal ini dapat mengakibatkan model cenderung lebih bagus dalam mengenali kelas mayoritas dibandingkan kelas minoritas, sehingga diperlukan strategi dalam penanganan nya.

3. Berikut merupakan outlier yang dimiliki oleh dataset kami



Gambar 4. Deteksi Outlier

Gambar 4 menunjukkan bahwa terdapat nilai ekstrem pada beberapa atribut dataset, yaitu *width* sebanyak 335 data, *height* sebanyak 336 data, dan *file size* sebanyak 332 data. Keberadaan outlier ini mengidentifikasi adanya variasi ukuran dimensi citra dan ukuran file yang cukup beragam dibandingkan mayoritas data.

4. Hasil pemeriksaan kami menunjukkan bahwa dataset tidak memiliki *missing value* atau data yang *corrupt*. Hal ini menunjukkan kualitas kelengkapan data tergolong baik dan tidak memerlukan proses imputasi atau penanganan data kosong.

	5. Ditemukan sebanyak 2 gambar duplikat dalam dataset. Keberadaan data duplikat akan diperhatikan karena dapat menyebabkan <i>bias</i> pada proses pelatihan model, terutama jika data yang sama muncul pada data <i>train</i> dan data <i>test</i> .
--	---

Rencana Metode

	Data Preprocessing
Teknik yang digunakan	1. Penanganan <i>Outlier</i> Berdasarkan hasil analisis yang telah dilakukan, ditemukan nilai ekstrem pada beberapa atribut dataset, yaitu <i>width</i> sebanyak 335 data, <i>height</i> sebanyak 336 data, dan <i>file size</i> sebanyak 332 data. Nilai ekstrem ini mengindikasikan adanya citra dengan dimensi yang jauh berbeda dari mayoritas data dalam dataset. Penanganan <i>outlier</i> pada penelitian ini dilakukan dengan menerapkan proses <i>resize</i> pada seluruh citra, yaitu menyeragamkan ukuran semua gambar menjadi dimensi tetap (misalnya 224 x 224 piksel). Dengan pendekatan ini, perbedaan dimensi antar <i>image</i> yang ekstrem dapat diatasi sekaligus memenuhi kebutuhan input model CNN yang memerlukan ukuran citra yang konsisten. Selain itu, normalisasi nilai piksel ke rentang 0-1 juga diterapkan untuk menstabilkan distribusi intensitas warna pada citra yang memiliki variasi ukuran file cukup besar.
	2. <i>Under Sampling</i> Pada aspek khusus dataset yang digunakan, diketahui bahwa dataset tersebut memiliki pembagian data yang tidak seimbang pada setiap kelasnya. Agar dapat menghindari terjadinya bias pada kelas mayoritas, maka digunakannya metode <i>under sampling</i>. <i>Under sampling</i> merupakan teknik <i>preprocessing</i> data yang digunakan untuk menangani <i>imbalanced dataset</i> dengan mengurangi jumlah data pada kelas mayoritas. Ketidakseimbangan dataset dapat mengakibatkan model <i>machine learning</i> cenderung memprediksi kelas yang memiliki jumlah dataset yang paling banyak, sehingga performa model pada kelas minoritas menjadi kurang optimal. Pada proses ini dataset pada kelas <i>Blight</i>, <i>Common Rust</i>, dan <i>Healthy</i> akan dipilih secara acak dan dihapus, sehingga hanya menyisakan 600 data pada masing-masing kelasnya. Untuk kelas minoritas yaitu <i>Gray Leaf Spot</i>, akan tetap dipertahankan pada jumlah awalnya yaitu 574 data.
	Feature Extraction
	<i>Convolutional Neural Network (CNN)</i> Digunakan untuk melakukan ekstraksi fitur visual pada citra daun jagung, seperti pola, tekstur, dan warna penyakit daun. Pada penelitian ini, CNN dengan arsitektur <i>MobileNetV2</i> digunakan sebagai <i>feature extractor</i> untuk menghasilkan representasi fitur yang lebih efektif sebelum proses klasifikasi dilakukan.

	Ensemble Classification 1. <i>Random Forest</i> Digunakan sebagai <i>ensemble classifier</i> untuk melakukan klasifikasi jenis penyakit daun jagung berdasarkan fitur hasil ekstraksi CNN. <i>Random Forest</i> bekerja dengan menggabungkan banyak <i>decision tree</i> untuk menghasilkan prediksi yang lebih stabil dan mengurangi risiko <i>overfitting</i> pada proses klasifikasi. 2. <i>XGBoost</i> Digunakan sebagai <i>ensemble classifier</i> berbasis <i>boosting</i> untuk meningkatkan performa klasifikasi penyakit daun jagung. <i>XGBoost</i> bekerja dengan membangun model secara bertahap untuk memperbaiki kesalahan prediksi sebelumnya, sehingga mampu menghasilkan akurasi klasifikasi yang lebih baik dan efisien pada data citra hasil ekstraksi fitur CNN.
Alasan pemilihan teknik/algoritma	Alasan pemilihan teknik <i>preprocessing</i> didasarkan pada karakteristik dataset citra daun jagung yang memiliki masalah <i>outlier</i> dimensi dan ketidakseimbangan kelas (<i>imbalanced data</i>). Teknik <i>resize</i> (menjadi 224 x 224 piksel) dan normalisasi piksel (0-1) dipilih untuk menyeragamkan ukuran gambar yang ekstrem serta memenuhi syarat input wajib arsitektur CNN agar pelatihan model lebih stabil. Sementara itu, teknik <i>under-sampling</i> dipilih untuk memangkas kelas mayoritas secara acak menjadi masing-masing 600 data guna mengatasi ketidakseimbangan dengan kelas minoritas (<i>Gray Leaf Spot</i>). Alasan utamanya adalah untuk menciptakan distribusi data yang adil, sehingga model tidak mengalami bias pada kelas mayoritas dan tetap optimal dalam mengenali penyakit pada kelas minoritas. Sedangkan pemilihan algoritma pada penelitian ini didasarkan pada karakteristik data citra daun jagung serta kebutuhan untuk memperoleh model klasifikasi yang akurat, efisien dan mampu menangani kompleksitas pola visual penyakit. Kombinasi CNN, <i>Random Forest</i>, <i>XGBoost</i> dipilih karena kemampuan masing-masing algoritma. CNN dipilih karena efektif dalam memahami pola yang kompleks. <i>Random Forest</i> dipilih karena memiliki ketahanan yang baik terhadap variasi data serta mampu memberikan hasil klasifikasi yang konsisten. Sementara itu, <i>XGBoost</i> dipilih karena memiliki performa prediksi yang tinggi melalui optimasi pembelajaran yang efisien. Kombinasi ini diharapkan mampu menghasilkan model klasifikasi yang akurat, <i>robust</i>, dan sesuai dengan karakteristik dataset penelitian.
	Penelitian ini dilakukan melalui beberapa tahapan utama, dimulai dari pengumpulan dataset hingga evaluasi performa model klasifikasi penyakit daun jagung. Dataset citra daun jagung yang telah dikumpulkan terlebih dahulu masuk ke tahap <i>preprocessing</i> untuk mengatasi karakteristik data yang tidak ideal. Tahap ini diawali dengan penanganan outlier dimensi, di mana seluruh citra yang memiliki ukuran ekstrem diseragamkan ukurannya melalui proses <i>resize</i> menjadi dimensi tetap (misalnya 224 x 224 piksel) guna

Langkah-langkah umum pengerjaan	memenuhi kebutuhan input model, serta dilakukan normalisasi nilai piksel ke rentang 0-1 untuk menstabilkan distribusi intensitas warna. Selanjutnya, dilakukan tahapan <i>under-sampling</i> untuk mengatasi masalah ketidakseimbangan kelas (<i>imbalanced dataset</i>). Proses ini dilakukan dengan memangkas jumlah sampel pada kelas mayoritas (<i>Blight</i>, <i>Common Rust</i>, dan <i>Healthy</i>) secara acak hingga menyisakan masing-masing 600 data, sementara kelas minoritas (<i>Gray Leaf Spot</i>) tetap dipertahankan pada jumlah aslinya yaitu 574 data. Hal ini dilakukan agar model tidak mengalami bias saat proses pelatihan. Selanjutnya, dilakukan proses ekstraksi fitur menggunakan metode <i>Convolutional Neural Network</i> (CNN) dengan arsitektur <i>MobileNetV2</i>. Model ini digunakan untuk mengambil fitur visual penting pada citra daun jagung, seperti pola bercak, tekstur daun, dan perubahan warna akibat penyakit. Hasil ekstraksi fitur kemudian digunakan sebagai input pada model klasifikasi. Pada tahap klasifikasi, digunakan dua metode <i>ensemble learning</i>, yaitu <i>Random Forest</i> dan <i>XGBoost</i>. <i>Random Forest</i> digunakan untuk menghasilkan klasifikasi yang stabil melalui kombinasi beberapa <i>decision tree</i>, sedangkan <i>XGBoost</i> digunakan untuk meningkatkan performa prediksi melalui pendekatan <i>boosting</i> secara bertahap. Setelah proses pelatihan model selesai, dilakukan evaluasi performa untuk mengetahui kemampuan model dalam mengklasifikasikan penyakit daun jagung. Metrik evaluasi yang digunakan pada penelitian ini meliputi: 1. <i>Accuracy</i>, untuk mengukur tingkat ketepatan prediksi model secara keseluruhan. 2. <i>Precision</i>, untuk mengukur ketepatan model dalam memprediksi setiap kelas penyakit. 3. <i>Recall</i>, untuk mengukur kemampuan model dalam mendeteksi data pada kelas yang sebenarnya. 4. <i>F1-Score</i>, untuk melihat keseimbangan antara nilai precision dan recall. 5. <i>Confusion Matrix</i>, untuk mengetahui distribusi hasil prediksi pada setiap kelas. Setelah itu, dilakukan perbandingan performa antara model <i>Random Forest</i> dan <i>XGBoost</i> untuk menentukan model terbaik pada klasifikasi penyakit daun jagung berdasarkan fitur hasil ekstraksi CNN.
---------------------------------	---